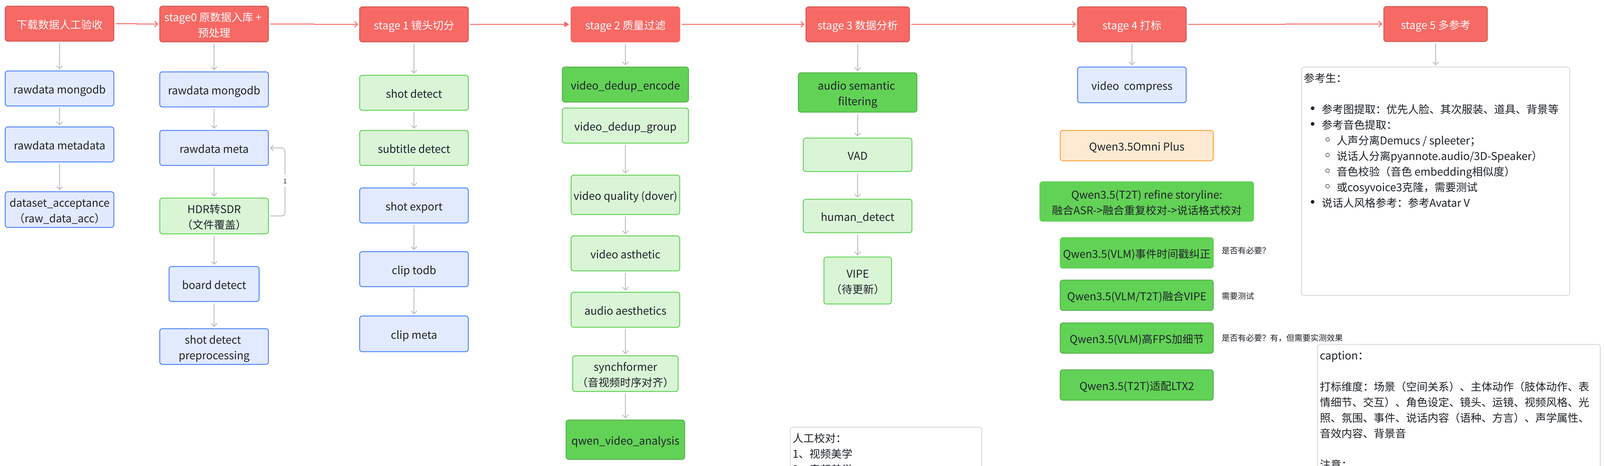

人工校对：
1、视频美学
2、音频美学
3、motion_quality
4、information_density
5、VIPE

每个维度1k条数据

数据统计、分布分析
(定义问题，考虑前置)

caption：

打标维度：场景（空间关系）、主体动作（肢体动作、表情细节、交互）、角色设定、镜头、运镜、视频风格、光照、氛围、事件、说话内容（语种、方言）、声学属性、音效内容、背景音

注意：
（1）优先保证叙事顺序，暂时放弃时间戳描述，api的时间戳不准。
（2）暂不考虑字幕，一方面字幕时间戳打的不准，一方面ltx模型结构需要适配时间戳理解；

~~方案1：~~
~~qwen3.5omni 一把出~~

方案2：
qwen3.5omni + VIPE

方案3：
qwen3.5/gemma4（visual） + VIPE + moss-audio（ASR） + qwen3.5omni（融合+音效）

改写：
1、长短标；
2、删除audio caption；
3、中英文；

兼容下游任务：
sft：尽可能详细，且覆盖下游
参考生：/cpfs01/users/zhangmingyang2/datasets/multi_ref2v/v3/datasets/caption/run_plan4.sh 和
Caption范式
音生：采用官方caption管道，基于qwen3omni
视频编辑：gap较大，暂不考虑

不同数据类型，设计不同的caption模板！！！
比如high_risk类型的数据，可以不描述speaker-asr等

补充说明：

Qwen3.5视频分析（多轮对话）：
- 内容分析：屏幕文字、动态文本、边框、水印、动态水印、画中画、视频特效；
- 运动质量：包括是否存在可运动主体、主体运动强度和画面动感；
- 信息密度：
- scene校验：判断stage1的导出切片是否为一个scene

audio semantic filtering：
- `stable_human_voice`：确认真实人声，并且连续完整发声或多个干净轮次能够提供可累计的身份依据；所有实质性主要人声都能稳定解释，且不存在高风险事实。
- `pure_non_speech`：可靠确认整段没有任何人类发声。纯器乐、自然环境音、机械声、人工音效和无人声掌声可以归入本类。
- `high_risk`：直接确认存在会影响人声身份或内容归属的风险事实。
- `uncertain`：人声存在性、多人结构或风险事实无法可靠确认，保留复核。

high_risk 指首频中存在明确的声学问题，导致我们无法稳定判断“谁在发声，以及内容应该归属于谁”。主要包括：人声以喊叫、呻吟、哭笑等带环发声为主；多人持续快速换人或反复抢话；多人声音明显重叠、齐声或合唱；背景人声、远场声、音乐和音效严重干扰；以及前后音色或声学状态发生无法解释的变化。只我们采用高精度判定，只有将到直接、明确的风险证据才标为 high_risk。如果只是疑似多人、疑似重叠，或者无法排除回声和音效，则归入 uncertain，不会直接判高风险。

TODO：
tag
人数和人体占比
人声占比（VAD）、
音频类型
benchmark除了评价维度，还得考虑数据分布维度。尤其是用户数据。
分析用户数据，包括tag
数据系统说明

CPT

qwen3.5omni plus
音视频事件描述
（每一个明显的音频和视觉细节）

VIPE：运镜tag

运镜tag+VLM：与画面事件绑定的运镜caption

storyline refine 01：（1）融合运镜caption。t2t/tv2t

storyline refine 02：（1）融合ASR+Text；（2）校对融合内容，特别是重复；（3）校对asr格式；（4）~~校对结尾时间戳~~

storyline refine 03：（1）高FPS补充动作细节

适配LTX2/H3 caption格式

SFT
（1）Speaker_ID+ASR一致性判断（MOSS）；
（2）根据过滤+tag筛选约10k条数据，人工清洗caption，包括运镜、画面幻觉、匹配错误等，不进行人工修改，只做筛选